

ĐẠI HỌC QUỐC GIA THÀNH PHỐ HỒ CHÍ MINH
TRƯỜNG ĐẠI HỌC KHOA HỌC TỰ NHIÊN
KHOA CÔNG NGHỆ THÔNG TIN



HỌC THỐNG KÊ

Lab Assignment 3

BÁO CÁO

Lớp: CQ2023/22

Giảng viên: TS. Ngô Minh Nhựt

Sinh viên: Đỗ Quốc Thịnh - 23120089

Thành phố Hồ Chí Minh, 05/2026

Mục lục

Danh mục hình ảnh	2
1 Câu hỏi 1 - So sánh CNN và MLP	3
2 Câu hỏi 2 - Xác định những lớp khó nhận nhất	3
3 Câu hỏi 3 - Tăng cường dữ liệu cho mô hình CNN	5
4 Câu hỏi 4 - Thử thách cải thiện mô hình CNN	6
4.1 Mục tiêu và giả thuyết đề ra	6
4.2 Kết quả thí nghiệm và thảo luận	6
4.2.1 Phân tích Learning Curves	6
4.2.2 Phân tích ma trận nhầm lẫn	7
4.3 Kết luận	8
5 Câu hỏi 5	8
5.1 Áp dụng Transfer Learning	8
5.2 Tối ưu hóa siêu tham số	8
5.3 Tăng cường dữ liệu nâng cao	8
5.4 Nghiên cứu sâu hơn về kiến trúc	9


Danh mục hình ảnh

1	Learning Curves của mô hình MLP	3
2	Learning Curves của mô hình CNN	3
3	Ma trận nhầm lẫn của MLP	4
4	Ma trận nhầm lẫn của CNN	4
5	So sánh model khi có và không có augmentation	5
6	Learning curve của model được cải thiện	6
7	Ma trận nhầm lẫn của mô hình cải tiến	7


1 Câu hỏi 1 - So sánh CNN và MLP

CNN cải thiện đáng kể so với MLP trên tập CIFAR-10, cụ thể theo báo cáo trong các file `cnn_results.md` và `cifar_mlp_results.md` như sau:

- MLP: Accuracy: 0.5150, F1-Score: 0.5132
- CNN: Accuracy: 0.7679, F1-Score: 0.7673
- Tăng: Accuracy: +25.29%, F1-Score: +25.41%



Hình 1: Learning Curves của mô hình MLP




Hình 2: Learning Curves của mô hình CNN


Qua 2 Hình 1 và 2 và 2 file báo cáo kết quả `cnn_results.md` và `cifar_mlp_results.md`, CNN rõ ràng thể hiện sự ưu việt toàn diện hơn MLP trên tập CIFAR-10.

2 Câu hỏi 2 - Xác định những lớp khó nhận nhất

Dựa vào confusion matrix, đối với cả 2 mô hình MLP và CNN, top 3 những lớp khó nhất, dễ nhầm lẫn nhất cho dự đoán nhãn đều khá giống nhau, cụ thể:



Hình 3: Ma trận nhầm lẫn của MLP



Hình 4: Ma trận nhầm lẫn của CNN

Với MLP:

1. Chó nhưng model dự đoán là mèo (219 lần)
2. Mèo nhưng model dự đoán là chó (198 lần)
3. Dê nhưng model dự đoán là chim (178 lần)

Với CNN: cũng tương tự như được cải thiện hơn


1. Chó nhưng model dự đoán là mèo (190 lần)
2. Mèo nhưng model dự đoán là chó (110 lần)
3. Mèo nhưng model dự đoán là chim (100 lần)

Ngoài ra, model cũng gặp khó khăn khi phân biệt Máy bay với Tàu, Ô tô với Xe tải, Ngựa với Dê, chủ yếu do nét tương đồng về hình dạng và bối cảnh khung hình giữa các bức ảnh. **Nguyên nhân gây ra sự nhầm lẫn:**

- **Chó và Mèo:** cả hai đều là động vật bốn chân, có đuôi và cấu trúc đầu tai và khung xương khá tương đồng trong không gian pixel nhỏ hẹp. Không gian, môi trường sống và sinh hoạt của chúng gần như giống nhau. Bộ lông cũng khá giống nhau.
- **Chim và Dê:** ở một số tư thế (ví dụ chim đang đậu trên cành hoặc dê đứng trong bụi rậm), các đường nét mảnh của chân dê và cánh chim có thể tạo ra các đặc trưng không gian giống nhau khi bị mờ hóa. Cả hai lớp này thường xuyên xuất hiện trên các phong nền thiên nhiên như rừng cây, bãi cỏ hoặc lá xanh.
- **Máy bay và Tàu:** có cấu trúc khá giống nhau, thon và dài, và đặt trên phong nền bầu trời hay biển đều có màu xanh dương khá tương đồng.
- **Ngựa và Dê:** ngựa và dê có thân hình và dáng đứng khá tương đồng, và bối cảnh chụp chúng đều giống nhau, có chứa cây, cỏ, bụi rậm, rừng.

3 Câu hỏi 3 - Tăng cường dữ liệu cho mô hình CNN

Data Augmentation thật sự có hiệu quả trong việc giảm overfitting của model. Hình bên trái Hình 5 so sánh độ chính xác của mô hình khi không có augmentation (đường màu xanh) và khi có augmentation (đường màu đỏ). Hình bên phải so sánh hàm mất mát.



Hình 5: So sánh model khi có và không có augmentation

Nhận xét:

- Baseline - đường màu xanh: Train Acc vọt lên rất nhanh nhưng Val Acc bị tụt lại phía sau, khoảng cách giữa chúng khá lớn, đây là dấu hiệu của overfitting.
- Augmentation - đường màu đỏ: Train Acc tăng chậm hơn do dữ liệu khó hơn, nhưng Val Acc bám sát Train Acc hơn.

Tuy nhiên, khi train cùng số lượng epochs là 50, phiên bản có Data Augmentation với tập train khó hơn, nên độ chính xác thấp hơn là điều dễ hiểu (chỉ đạt 71.94% theo file báo cáo `cnn_aug_results.md`). Nhưng nếu train đủ nhiều, tăng lên 100 chẳng hạn thì mô hình có Data Augmentation có tính khái quát hóa cao hơn, độ chính xác cũng sẽ được cải thiện hơn. Còn mô hình CNN baseline có thể đạt độ chính xác 99% trên tập train, nhưng trên tập validation vẫn quanh quẩn 76-79%.

Kết luận: Tăng cường dữ liệu thực sự giúp giảm overfitting, độ bám sát về accuracy và loss của 2 đường màu đỏ trên tập train và validation chứng minh điều đó.

4 Câu hỏi 4 - Thử thách cải thiện mô hình CNN

4.1 Mục tiêu và giả thuyết đề ra


Chúng ta tập trung vào việc cải thiện khả năng tổng quát hóa và giảm hiện tượng overfitting của mô hình CNN cơ bản. Các cải tiến được áp dụng bao gồm:

- **Deeper CNN architecture:** Tăng số lượng convolutional blocks từ 2 lên 4 blocks để trích xuất các đặc trưng phân cấp sâu hơn.
- **Global Average Pooling (GAP):** Thay thế lớp *Flatten* bằng GAP để giảm thiểu số lượng tham số huấn luyện, từ đó hạn chế overfitting tại các lớp fully-connected.
- **Early Stopping & Model Checkpoint:** Tự động dừng huấn luyện khi hàm mất mát trên tập validation (*val_loss*) không còn cải thiện sau 7 epochs.

Giả thuyết dự đoán: Việc kết hợp kiến trúc sâu hơn cùng lớp GAP sẽ giúp mô hình hội tụ tới một nghiệm tối ưu có khả năng tổng quát hóa tốt hơn, trong khi Early Stopping sẽ ngăn chặn mô hình bước vào giai đoạn học vẹt dữ liệu huấn luyện.

4.2 Kết quả thí nghiệm và thảo luận

4.2.1 Phân tích Learning Curves




Hình 6: Learning curve của model được cải thiện

Dựa trên Hình 6, quá trình huấn luyện đã tự động dừng lại ở epoch thứ 26 nhờ cơ chế **Early Stopping**.

- **Accuracy:** Độ chính xác trên tập huấn luyện đạt khoảng 83.65%, trong khi trên tập validation duy trì ở mức trên 80%. Khoảng cách giữa hai đường cong được kiểm soát tốt, chứng tỏ các phương pháp regularization (*Dropout*, *GAP*) đã hoạt động hiệu quả. Độ chính xác trên tập test đạt 80.68%, cải thiện 3.89% so với CNN ban đầu (76.79%).
- **Loss:** Hàm mất mát giảm ổn định. Tuy có những sự biến động ở các epoch từ 5-15 trên tập validation, nhưng cơ chế **Model Checkpoint** đã giúp lưu lại trạng thái tốt nhất của trọng số trước khi hiện tượng quá khớp xảy ra.

4.2.2 Phân tích ma trận nhầm lẫn



Hình 7: Ma trận nhầm lẫn của mô hình cải tiến

Phân tích ma trận nhầm lẫn Hình 7 cho thấy mô hình Advanced CNN đạt hiệu suất rất cao ở các lớp như *Automobile* (913), *Frog* (917) và *Truck* (882). Tuy nhiên, các thách thức đặc trưng của tập CIFAR-10 vẫn tồn tại:

- **Cặp nhầm lẫn chính:** Lớp **Dog** bị dự đoán nhầm thành **Cat** 170 lần. Điều này là do sự tương đồng cao về đặc trưng hình thái (tai, mũi, cấu trúc khuôn mặt) ở độ phân giải thấp.

- **Cặp nhầm lẫn thứ cấp:** **Cat** bị nhầm thành **Frog** 100 lần, **Cat** bị nhầm thành **Bird** 86 lần, **Ship** nhầm thành **Airplane** 64 lần, khả năng cao do sự tương đồng về hình dạng và màu sắc phong nền như màu xanh lá cây, xanh nước biển trong các ảnh thiên nhiên.

4.3 Kết luận

Kết quả thực nghiệm hoàn toàn ủng hộ giả thuyết ban đầu. Mô hình Advanced CNN không chỉ đạt độ chính xác cao hơn so với baseline (vượt ngưỡng 80%) mà còn duy trì được sự ổn định nhờ các kỹ thuật tối ưu hóa hiện đại. Việc thay thế **Flatten** bằng **GlobalAveragePooling2D** là cải tiến mang lại hiệu quả cao nhất về mặt tối ưu tham số trên mỗi đơn vị độ chính xác đạt được.

5 Câu hỏi 5

Nếu có nhiều thời gian hơn, em sẽ cân nhắc thử một số hướng cải tiến như sau:

5.1 Áp dụng Transfer Learning

Đây là phương án hiệu quả nhất để đột phá độ chính xác.

- Kế hoạch: Sử dụng các kiến trúc mạnh mẽ đã được huấn luyện sẵn trên tập ImageNet như ResNet50, MobileNetV2 hoặc EfficientNet.
- Lý do: Thay vì học từ đầu với các lớp Conv đơn giản, việc tận dụng các đặc trưng đã được tối ưu từ hàng triệu ảnh sẽ giúp mô hình vượt qua ngưỡng 85-90% accuracy trên CIFAR-10 một cách dễ dàng.

5.2 Tối ưu hóa siêu tham số

Kế hoạch: Thực hiện Grid Search hoặc Random Search để tìm bộ tham số tối ưu cho:

- Learning rate ban đầu và các cách giảm learning rate (Learning rate scheduler).
- Cường độ Dropout tại từng block để cân bằng giữa học đặc trưng và chống overfitting.
- Kích thước Batch size (ví dụ thử nghiệm với 64, 128, 256) để tìm điểm cân bằng giữa tính ổn định và tốc độ hội tụ.

5.3 Tăng cường dữ liệu nâng cao

Kế hoạch: Áp dụng Mixup (trộn hai ảnh khác lớp) hoặc Cutout (xóa ngẫu nhiên một vùng ảnh).

Lý do: Những kỹ thuật này buộc mô hình phải học các đặc trưng bền vững hơn, giúp xử lý tốt các ảnh có vật thể bị che khuất hoặc nền phức tạp – những thách thức chính của tập CIFAR-10.

5.4 Nghiên cứu sâu hơn về kiến trúc

Thử nghiệm các khối xử lý hiện đại thay vì chỉ dùng Conv2D truyền thống.

Kế hoạch: Thêm các khối Residual Connections (như trong ResNet) để giải quyết vấn đề triệt tiêu đạo hàm khi mạng trở nên quá sâu.

Lý do: Điều này giúp xây dựng các mạng có độ sâu 50-100 lớp mà vẫn hội tụ tốt, giúp trích xuất các đặc trưng ngữ cảnh phức tạp mà các mạng nông (shallow networks) không thể bắt được.

-HẾT-